Création d’un package pour R

M2 SISE 2026-2027

Analyse discriminante prédictive

Algorithmes et Outils pour l’interprétation des résultats

Objectif du projet

- Création d'un package proposant l'analyse discriminante linéaire prédictive
- Package que l'on peut installer directement à partir de GitHub.
- Le package intègre un fichier d'aide en anglais aux normes R. c.-à-d. description des fonctions, de leurs paramètres, des objets fournis en sortie, de la lecture des résultats, avec des exemples d'utilisation (voir par ex. ?glm du package stats)
- **A réaliser en équipes de 3 étudiants (4 étudiants pour une des équipes)**

Cahier des charges - Obligatoire

Cœur du projet : implémentation de l'algorithme d'analyse discriminante linéaire prédictive

1. Implémenter le cœur de l'algorithme de la manière la plus efficace possible
2. La variable cible est catégorielle ($\geq$ 2 modalités)
3. Fournit les coefficients du modèle prédictif
4. Indicateurs d'évaluation globale du modèle et de la pertinence des variables
5. Stratégie pour l'intégration des explicatives catégorielles
6. Stratégie de sélection de variables

Cahier des charges - Obligatoire

La classe de calcul doit être implémentée selon la norme R6. Elle doit présenter (alignez-vous sur le formalisme des librairies telles que « Scikit-Learn / Python ») :

1. Un constructeur, avec les paramètres éventuels (à vous de voir)
2. La méthode $fit(X, y) qui lance la modélisation sur les données d'apprentissage. « X » représente un data frame comportant l'ensemble des variables actives, « y » un vecteur de variable catégorielle (factor)
3. La fonction $predict(X) qui prend en entrée un data frame X de variables explicatives compatibles avec celui présenté à fit(), et qui rattache chaque observation de X à l'une des classes ($predict_proba(X) pour les probabilités d'appartenance).
4. La procédure $print() qui affiche les informations succinctes sur le modèle (à vous de voir le contenu)
5. La procédure $summary() qui affiche les informations détaillées (à vous de voir aussi)
6. Votre objet peut exposer une série de propriétés qui peuvent être exploitées par la suite, à vous d'en définir la teneur.

Cahier des charges - Obligatoire

- Une application R SHINY qui a pour vocation de présenter les fonctionnalités de votre package. Elle doit permettre de :
  - Sélectionner un fichier de données (CSV – séparateur tabulation – au moins ; autre éventuellement, ex. « xlsx »…)
  - Choisir les variables explicatives et les variables illustratives
  - Lancer les calculs et présenter les résultats, avec en particulier une mise en valeur de vos sorties
  - De déployer le modèle sur des individus supplémentaires, soit individuellement, soit regroupés dans un fichier de données.
  - Autres… ?

Cahier des charges - Optionnel

- A vous de voir les fonctionnalités additionnelles que vous jugez utiles… (ex. régularisation, traitement des très grandes dimensionnalités, aide à l'interprétation supplémentaire, représentations graphiques, parallélisation des calculs, autre ???? …)

A rendre

- Un rapport en français au format PDF de présentation de votre travail. Il doit être rédigé en LaTeX (source .tex doit être fourni). Il doit indiquer les formules, stratégies, algorithmes utilisés pour produire les résultats. Il doit décrire également l'architecture de votre programme, modules R, fonctions, détail des objets générés, description de vos algorithmes et implémentations en pseudo-code, des informations que vous souhaitez mettre en avant dans vos sorties (douze pages maximum [sans les annexes et biblio])
- Soyez précis sur vos références (bibliographique). Je dois pouvoir les consulter.

- Le projet doit être hébergé sur GitHub.
- Le package doit pouvoir être installé directement en ligne à partir de GitHub. Il doit comporter les jeux de données exemples utilisés dans le tutoriel.

- Le code source du package et les documents associés (aide, etc.).
- Une copie du package au format ZIP (ou tar.gz) directement utilisable sous R (plan B au cas où l'installation en ligne est défaillante).

- L'application R SHINY avec tous les éléments permettant de le faire fonctionner.

- Sur GitHub, un tutoriel (reproductible) en anglais montrant l'utilisation des fonctionnalités de votre package doit être disponible sur GitHub. Montrez au moins le fonctionnement de $fit() et description des sorties ; puis montrez également le fonctionnement de l'application SHINY.

Critères d'évaluation

- Qualité et clarté du rapport (en français)
- Qualité de la documentation du package (en anglais)
- Qualité de la programmation – Commentaires / documentation du code source
- Qualité de l'application interactive R SHINY

- Qualité du package, notamment l'installation en ligne
- Fonctionnement sécurisé (pas de plantage, calculs corrects)
- Rapidité d'exécution et appréhension des grandes volumétries (attention, ce serait très dommage que votre package plante à cause d'une librairie externe que vous utilisez, à vous de vous assurer de leur robustesse et intégrité !)
- Richesse fonctionnelle (au-delà du cahier des charges obligatoire)
- Utilisabilité (facilité pratique) des fonctions implémentées

Calendrier

- Diffusion du sujet : vendredi 16 octobre 2026
- Retour attendu : dimanche 15/11 au soir
- Soutenances : semaine du 29/11

- A faire :
  - Mettre votre projet complet (rapport, package, source, etc.) sur un drive quelconque. Tout ce qui me permet de retracer et reproduire votre travail.
  - M'avertir par e-mail et m'envoyer le lien à l'adresse : ricco.rakotomalala@univ-lyon2.fr
  - Sujet : [SISE – Prog. R – Numéro d'équipe] Noms des étudiants